小主角 · Once Upon Me —— 参赛技术文档

> **一句话定位**：说出孩子的名字和爱好，得到一本以他为主角、用父母的声音朗读、可以反复探索的定制绘本。

项	内容
赛事	2026 第九届传智杯 · AI WEB 网页开发挑战赛
赛道主题	智启未来：AI 驱动的 Web 应用创新挑战
选题方向	方向 3：多模态 AI 创意平台
队名	破晓微光 | **成员**：范嘉庆、胡锦宇 | **学校**：太原理工大学
组别	A 组 | **指导老师**：王琦 | **赛区**：北部赛区
在线演示	https://lbx99.xyz　**评审账号**：`123456` / `123456`（自己注册也赠 2 本）
代码仓库	https://github.com/lbx-ux/once-upon-me（Public）

证据等级：【A】本仓库已实测，附命令或文件路径，可当场复现；【B】已核实的外部事实，附来源与日期；【假设】我们的推算或设定，不是调研结论。测不出来的写「未量到」，不用形容词补。

五分钟速览

#	读数	复核
1	一本书的输入只有三样：一句话、一张角色卡、一档声音	工作台 `/home`；`BookRequest`
2	一致性 Agent：出图 → 比对 → 判分 → 诊断回灌 → 重画，上限 3 次	`engine/illustrate.ts`
3	**1710 条测试 / 130 个文件全绿**	`pnpm test`（4.9 s）
4	引擎 **0.06 秒**跑完一本 6 页的书，不联网、不花钱	`engine-run.mts --mode=stub`
5	MCP 真会话 **14/14**，与 CLI 的 32 条事件语义相同	`mcp-session.mts`
6	20 页 API 成本 **¥5.8–11.6**	`cost-model.mts`

目录

- 一、项目概述
- 二、需求分析
- 三、系统架构设计
- 四、AI 技术方案
- 五、核心功能实现
- 六、测试与部署
- 七、总结与展望
- 八、创新点清单
- 附录：写作依据对照表

一、项目概述

1.1 三个趋势，落到一条主线

多模态生成能画出可用插画，语音合成能克隆普通人的音色，Agent 与 MCP 把模型能力从一次问答扩展成可编排的工作流。这些趋势对本项目只有一个具体含义：

模型能画一张好图，不等于能把同一个孩子画 20 次。

孩子翻到第 1 页和第 8 页，两张脸必须被认成同一个人；父母的声音念到第 7 页，不能换讲述者；故事在岔口停下时，孩子选的那条路必须已经画好。三件事都不能靠「换更大的模型」自动成立，要靠工程兜住：

- **跨页一致性**：角色卡 8 条锚点 + 参考图锁脸 + 视觉比对 + 不达标重画；
- **声音一致性**：克隆一次、全书复用，情绪标签跟着每页 `mood` 走；
- **阅读零等待**：生成与阅读解耦，书是盘上的资产，翻页不调模型。

所以本项目不是「又一个 AI 生成器」，而是**把一次生成变成可复用产物的个性化内容引擎。**

1.2 问题与产品定义

市面个性化童书能把孩子的**名字**印进预先画好的插图，换不掉**形象**，更谈不上**声音**；免费 DIY（豆包 + 即梦 + 剪映）什么都能做，但要家长自己写、画、配、剪，估计 **4–8 小时/本**【假设：未计时，是下界估计】。

本项目把输入压到三样：

输入	家长做什么	引擎拿它做什么
一句话	写「想讲什么」，可点 12 个主题卡	编故事；检索这个家庭写过的旧文本作正例 / 反例
一张角色卡	传照片或手填 8 条锚点，逐条核对	派生唯一角色段；每页锁脸；画完逐条核对
一档声音	录 30 秒，或选预置音色	克隆 / 合成；正文、提问、两个选项各自有朗读

一本故事，两种形态。 形态由引擎的一个入参 `form` 决定，没有两套结构，也没有两个入口函数。

形态	场景	交互
独读版（线性）	睡前	全屏翻页，一屏一图一句；**不给孩子选择的机会**——越选越兴奋，睡不着
共读版（一棵树）	白天陪玩	恰好一个选择点，两个大按钮；孩子不识字，选项走**「大图标 + 语音朗读」双通道**；两支各自收尾

判据很土：**去掉互动，绘本仍成立；去掉绘本，互动不成立。** 选择点之后**一次生成都不发生**——书是预生成的，阅读顺序就是你选的那条路。

1.3 目标用户与真实场景

用户	场景	他要什么	我们怎么满足
3–8 岁孩子	睡前 10 分钟；白天一个人翻	自己出现在画里；不识字	锁脸；每页朗读；选择点图标 + 语音

用户	场景	他要什么	我们怎么满足
25–40 岁家长	想给孩子专属的东西，不会写不会画	一句话能做；能改；便宜	故事闸门先改字再出图；三档定价（§7.3）
异地 / 留守家庭	父母在外，孩子跟祖辈	爸妈的声音；不需操作	30 秒克隆；自动朗读与自动翻页
幼儿园 / 公益	一个班每人一本；教室网络差	批量、可控成本、断网	预生成；离线回放；机构按班年费（未谈过，§7.3）

★ 社会价值必须说清：本项目**没有做过任何一家留守家庭的访谈**，也没有与公益组织或学校接触过。上表是「产品能力对得上场景」，不是「场景已被验证」。

1.4 团队与分工

范嘉庆、胡锦宇，指导老师王琦。项目**不按前端 / 后端切两半**：两人共同完成全部模块，按功能纵向负责，结对编程 + 交叉 review——一人写实现，另一人写判据与探针，合并前互查。理由很实际：这个项目的难点都长在边界上（引擎与 UI 的 seam、事件协议、一致性闭环），按层切会把边界切成两半，没人对整条链路负责。

协作约束写进仓库：三条闸门必过（`format:check` / `lint` / `typecheck`），动配色再加 `check:colors` / `check:scrim`；每处「刻意」的取舍留注释与实测台账（`docs/known-tradeoffs.md`，5000 余行）。

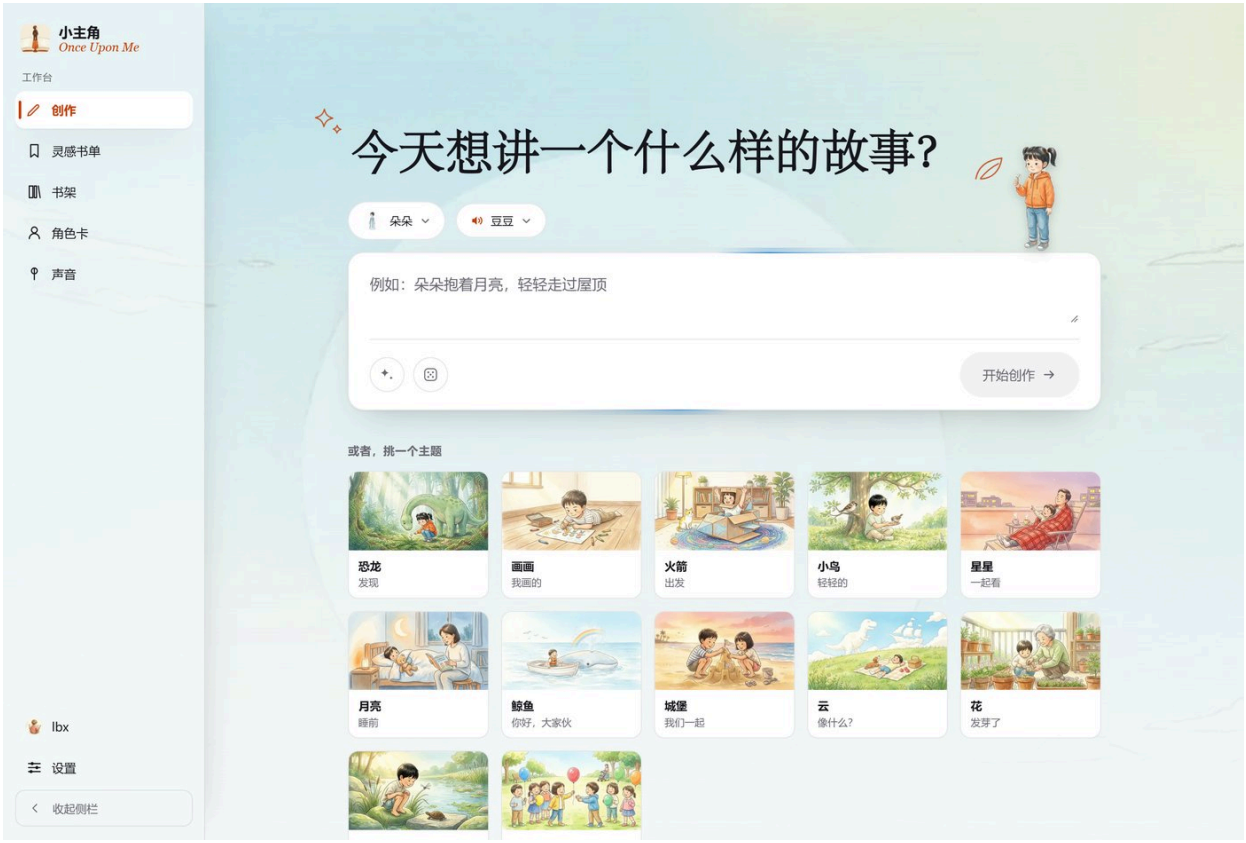
1.5 交付物与规模

层	交付物	规模【A】
前端	首页、工作台、阅读器、书架、书单、角色、声音、账号、管理页、隐私	444 个 TS/TSX，91,334 行；19 页 + 47 条 API
引擎	四个动作、事件协议、树、规划、出图、配音、审核；RAG 检索	不 import React，node 可跑；种子 96 跨页 ≈ 4.3k token
AI 接入	文本 / 图像 / 视觉 / 语音四类能力；MCP 手写 JSON-RPC，7 条工具	4 类能力、4 家适配器；14/14 条会话判据
后端	Spring Boot 3.3.5，只管账号、权限、音色、额度	77 个 Java 文件，8 张表
资产	12 张封面、12 本样书（96 跨页）、演示书、立绘、朗读	`public/` 约 76 MB
质量	130 个测试文件 / 1710 条；87 个探针与部署脚本	`pnpm test` 4.9 s

1.6 四张图，按用户真走一遍的顺序



首页：12 张封面绕成 3D 环，正中一句「开始创作」。手机上环整块不演，12 张封面一张不取（§5.8）。



工作台：一句话 + 角色卡 + 声音，就是这本书的全部输入；右侧交代这一轮要画几张图。



独读版：一屏一图一句，刻意不给孩子选择的机会。



共读版：故事在岔口停下，两个大按钮各带图标与朗读；这一屏之后零生成。

二、需求分析

2.1 用户画像

孩子的判据是「能不能自己读下去」：不识字、注意力短，所以一页一图一句、每页有声、翻页跟手。家长是决策者，判据是「别让我学软件、别让我白花钱」：一句话可用、故事可逐条改、出图前知道要画几

张、内容有审核。异地家庭多一层约束：祖辈不会操作，孩子那台设备最好打开就能听，所以自动朗读与自动翻页是必需项而不是加分项。机构关心的是「同一流程跑 N 次、成本按本算、教室断网也能读」。

2.2 痛点拆成可验收的需求

#	痛点	需求	验收判据（可机械检查）
P1	换名字容易换形象难；同一本书里不像	跨页一致性	每页与卡比对 ≥ 阈值；不达标重画；未核对不算通过（§4.3）
P2	家长不会写故事	一句话生成结构化故事	Schema + 树形双校验；带路径重试；共读版页数由算术钉死（§4.1.5）
P3	生成几分钟到几十分钟，阅读不能等	生成与阅读解耦	阅读器零模型调用；断线可按 `seq` 重放（§3.4）
P4	孩子不识字，选项看不懂	选项双通道	图标 + 朗读；图标来自固定词表，不自造（§5.5）
P5	改一个字就重画整本	故事闸门	编故事与逐页画是两个动作；改字不出图，点「就按这个画」才花钱（§5.2）
P6	内容安全靠运气	三处闸门 + 兜底	输入闸拦截时 0 次模型调用；文字闸带条款 id；画面审核单独读数（§4.8）
P7	成本与时间不可预期	成本可算、进度可看	出图次数 / 成本 / 阶段进事件与清单（§5.6）
P8	换模型要改代码、停机	模型与密钥外置	零硬编码模型 id；管理页改完不重启；响应不回显 key（§5.7）

2.3 功能需求（含 AI）

ID	功能	类型	说明	落点
F1	一句话开一本	AI	主题 + 年龄档 + 爱好 → 结构化故事表；流式进度	`POST /api/books`, `engine/plan.ts`
F2	共读版两步规划	AI	先提纲、再分段展开；树形与页数由引擎拼	`plan-shared.ts`, `story-outline.ts`
F3	角色卡	AI + 数据	照片读数 → 8 条锚点（建议）→ 角色段与核对清单	`character-card/`, `/api/cards/*`
F4	逐页出图 + 一致性	AI Agent	参考图锁脸；比对；诊断回灌；重画 ≤3；失败图也落盘	`engine/illustrate.ts`
F5	封面	AI	3:4，也锁脸；画面审核不过则整本失败（刻意取舍）	`illustrateCover`
F6	配音	AI	正文 + 提问 + 两个选项，≤4 段/页；情绪标签；克隆音色	`engine/narrate.ts`
F7	故事闸门	交互	展示这一版故事，家长逐条改，改完才出图	`StorySheet`, `PUT /story`
F8	两台阅读器	交互	独读线性；共读一个岔口；自动朗读与翻页	`components/reader/`
F9	过程可视化	交互	阶段轨、每页状态、重画原因、断线重放	`events.ts` + SSE + `frames.ts`
F10	书架与归属	数据	按账号分片；服务端渲染；删除凭据按位置报数	`/shelf`, `asset-scope.ts`

ID	功能	类型	说明	落点
F11	管理页	运维	四张卡改模型 / 地址 / key，立刻生效，不回声 key	`/admin`，`settings/server-env.ts`
F12	MCP	AI 工具	7 条工具；异步出图；进度通知；与 CLI 同一代码路径	`mcp/server.mts`，`lib/mcp/tools.ts`
F13	额度与兑换	运营	按本扣减；开户赠 2 本；兑换码只存 HMAC 与后四位；对账差	`server/.../credit/`，`/redeem`
F14	分享与打印	交付	只读链接（30 天可收回）；A4 打印 / 存 PDF；站内信	`/r/<票>`，`/print/<书号>`，`/notices`
F15	隐私说明	合规	存了什么、发给谁、留多久、怎么删；不需要登录	`/privacy`，`PrivacySheet.tsx`

2.4 非功能需求

维度	要求	现状与读数【A】
性能	LCP < 2.5 s，CLS ≈ 0，手机不横向溢出	九格全「好」：首页 LCP 488 ms、CLS 0.000、TBT 92 ms；首屏 JS 168 kB
可用性	一步失败不终止整条流；断线能续；已生成的书不依赖供应商	非致命 `error` + 页级失败；`events.jsonl` 重放；回放包可离线跑
安全	密钥不入库；内容三处闸；照片与录音不落盘	`check:secrets`；输入闸 0 调用；`pnpm check:family` 满盘搜对照针
可维护性	引擎不依赖 UI；模型不写死；提示词有版本	ESLint 对 engine/schemas/prompts/rag 禁 React 与 `next/*`；`*_MODEL` 全在 env
可测试性	纯逻辑可单测；浏览器事实用真帧量	1710 条 Vitest；87 个探针，每个文件头写清量什么、判据几条
成本	单本可算、可解释；重画是最大变量	5.8–11.6 元/20 页（换家前口径）；重画 1.33–2.00 次/页
运营	陌生人不靠站长也能走完；额度可追账	开户赠 2 本（`refNo=welcome` 幂等）；`book_credits` 只追加，余额与账本恒等

2.5 与现有方案对比

维度	Wonderbly 类（纸质）	豆包 + 即梦 + 剪映	直接对通用模型聊	本项目
个性化到哪层	名字 + 献词	取决于家长水平	文本	**形象（8 锚点 + 参考图）、声音、故事、形态**
谁动手	下单	家长 4–8 小时【假设】	逐轮对话	说一句话
单本成本	$29.99–39.99（≈¥210–280）【B】	¥0 + 人工	订阅费	**¥5.8–11.6**（20 页，换家前）【A】
到手形态	纸质精装，等物流	视频 / 图集	聊天记录	可立刻读的绘本：翻页、朗读、选择点、预生成

维度	Wonderbly 类（纸质）	豆包 + 即梦 + 剪映	直接对通用模型聊	本项目
能不能改	改不了	每改一次都是重做	能改但不成书	故事闸门逐条改；改字不花钱
读时要不要网	不涉及	要	要	**不调模型**；整本在盘上（设备仍需连服务器）

三句话概括差异：别人卖一本印好的书，我们卖一个能持续产出书的引擎（角色卡与音色跨书复用）；别人把一致性交给模型，我们做成可判分的闭环；别人把生成与阅读绑在一起，我们拆开。

2.6 不做什么

- **不做多层分支（≥2 个选择点）**：孩子不识字，两个选项够；1 层时 27% 的书有一支永远读不到，2 层 43%、3 层 64%。
- **不做实时对话式生成**：一本要几分钟到几十分钟；对话会把等待藏起来，不是解决它。
- **不做端侧推理（WebGPU / Transformers.js）**：没做，也不宣称；端上是预生成资产的离线阅读。
- **不做支付 / 订阅**：今天能收钱的形态是对公转账；额度只从开户赠送、兑换码与站长补发进来。**只读分享与打印 / 存 PDF 已经做了**，离线包与推送到设备仍然没有。

三、系统架构设计

3.1 总体架构

```
flowchart LR
  U["浏览器<br/>页面与阅读器"]
  subgraph Next["Next.js 15：前端 + BFF + 引擎"]
    R["Route Handlers<br/>/api/*"]
    E["引擎 src/lib/engine<br/>不 import React"]
    P["providers<br/>文本 / 图像 / 视觉 / 语音"]
    S["资产存储<br/>books/书号 + events.jsonl"]
    G["RAG 索引<br/>index.seed.json"]
  end
  subgraph Java["Spring Boot：只做账号与额度"]
    J["登录 / 会话 / 权限 / 音色记录 / 额度账本"]
  end
  DB[("MySQL 8 / H2")]
  V["供应商：DeepSeek / 阿里云百炼"]
  U -->|"同源 fetch / SSE"| R
  R --> E
  E --> P
  E --> S
  E --> G
  R -->|"X-Internal-Token"| J
  J --> DB
  P -->|"HTTPS"| V
```

三条要读出来的边界：

1. **浏览器只跟 Next 说话。** 会话票在 httpOnly cookie 里，一个字节不回给 JS；Next 带内部 token 打 Java。
2. **Java 只回答「你是谁、能不能创作、你的音色是哪条、还剩几本」。** 它不认识模型、不碰 prompt、不碰作品字节。
3. **引擎不读环境变量、不 new 适配器、不碰盘。** 依赖全部注入，所以 node 脚本、Route Handler、测试跑的是同一条代码路径。

归属 Next（`src/`）	归属 Java（`server/`）
模型密钥、`serverEnv()`、模型配置	手机号 / 密码、会话票、创作权（一位）
引擎、prompt、资产字节	users / user_permissions / sms 两张 / voices / credit 三张，共八张表
BFF 路由（`/api/*`）	短信频控、登录失败锁、管理页动作、额度扣减与兑换

3.2 前端分层与组件

层	内容	约束
路由页面	`src/app/`：19 个页面路由 + 47 条 API	能服务端渲染就服务端渲染；书架按账号分片
组件	`src/components/` 按域分目录	样式与组件同目录同名，`globals.css` 里 `@import`；不用 Modules
纯逻辑	`src/lib/`：树、帧、排序、校验、阅读路径、检索、MCP 协议	不碰 DOM 的进纯函数，进 Vitest
引擎	`engine/`：四动作 + 事件 + providers	**禁 import React / next / components / window / document**
设计系统	令牌只在 `globals.css` 的 `:root` 定义一次	组件只消费 `var(--x)`；写死颜色由 `check:colors` 抓

用户真正会走的页面：`/` 首页 → `/login` → `/home` 工作台创作输入 → `/create` 故事闸门与画桌 → `/reader/[bookId]` 阅读器；旁路是 `/shelf` 书架、`/booklist` 12 本样书、`/character` 角色、`/voice` 音色、`/redeem` 兑换、`/notices` 站内信、`/account` 账号、`/admin` 管理页、`/privacy` 隐私说明；交付出去的两条是 `/r/<票>`（只读分享）与 `/print/<书号>`（A4 打印）。

3.3 状态管理

跨屏共享的只有三样：账号（`AuthProvider`）、音色（`VoiceProvider`）、这一轮的事件流（`use-run-stream` / `use-run-poll`）。没有需要全局 store 的状态，所以不引 Zustand / Redux。

状态	载体	为什么不用全局 store
登录态	Context + 服务端校验	它由 cookie 决定，store 只是镜像；两处真值会漂
音色	Context + `/api/voices`	跨屏共享的只是「当前用哪个」
生成进度	SSE → 本地 reducer	进度是流，不是快照；store 存不住「第 7 页第 2 次」

状态	载体	为什么不用全局 store
故事草稿	服务端 `story.json` + 自动保存	家长可能改十分钟；本地一份会在刷新后与盘上分家

3.4 数据流：事件是协议，返回值是资产

浏览器 `POST /api/books` → Route Handler 调 `planBook()` → 引擎每发一条事件，**先写 `events.jsonl`、再入 SSE 流**；故事草稿落 `story.json`，收尾发 `plan-ready` 后关闭。断线后 `GET /api/books/<id>/events` 按 `seq` 重放同一轮。

四条约定写在 `app/api/books/route.ts` 文件头：**先落盘再入流**（客户端看见的必须是日志里有的子集）；**客户端断开 ≠ 后端停手**（入流单独 try/catch）；**硬失败变成一条 fatal 帧**（头已发出，改不了状态码）；**fatal 之后必须 close()**（否则浏览器永远等在那里）。事件头统一带 `seq` / `at` / `stage` / `pageNo` / `attempt`，`seq` 每本书从 1 起，重连与日志对齐靠它，不靠时间戳。

3.5 关键接口

方法	路径	作用	形态 / 鉴权
POST	`/api/books`	只编故事，SSE 吐过程	SSE；`text` 能力；登录 + 创作权
POST	`/api/books/<id>/illustrate`	按盘上那版故事出图	同机租约；已有清单回 409
GET	`/api/books/<id>/events`	重放这一轮事件	SSE；帧格式与实时流逐字一样
PUT	`/api/books/<id>/story`	家长改过的故事写回	只过信封校验；改字不出图
POST	`/api/books/<id>/pages/<n>`	单页重画 / 重配	真花钱；`attempt` 接着数
POST	`/api/voice/clone`	30 秒样本 → voiceId；样本销毁	需授权凭据 `consentRef`
PATCH	`/api/admin/model-config/<能力>`	改模型 / 地址 / key；立刻生效	**响应里一个 key 都没有**
POST	`/api/books/<id>/publish`	草稿 → 成品（幂等）	本人；画面 `flag` 的页会挡发布
POST	`/api/books/<id>/share`	签一条只读分享票	本人 + 已画完；盘子只存哈希
GET	`/api/credits`	余额与只追加的流水	登录
POST	`/api/credits/redeem`	兑换码入账	登录；库里只存 HMAC 与后四位
GET	`/api/notices`	站内信（画完一本有一封）	登录；保留 90 天

3.6 部署形态

```
Nginx :443（:80 → 301）
├─ /          → Next 127.0.0.1:3000
└─ /backend/  → Java 127.0.0.1:8080（要内部 token）→ MySQL 3306

证书：Let's Encrypt，certbot 每天自己看一眼，到期前 30 天续
代码：/opt/xiaozhujue/            构建到 .next-new，健康检查过了再换，失败回滚
作品：/var/lib/xiaozhujue/assets 与代码分开——合在一起手一抖就是真实的数据损失
```

四、AI 技术方案

4.0 选型理由：为什么是这几家、为什么不是那几件

选型不按「哪家最强」拍，按**这条流水线真正会坏在哪儿**拍。所有模型名都只是默认推荐值：产品形态是「模型与密钥由站长在管理页配置」（ADR-0009 取代 ADR-0008 的「用户自带」），换一家改环境变量，不改代码。

这一格	默认选择	为什么是它	为什么不选另一条路
文本（规划 / 改写）	`deepseek-flash`	结构化 JSON 稳定；同一网关里能做视觉，省一套 key 与一套超时；思考链可显式关	思考链默认开时，4096 预算下实测正文 **0 字**、思考 9072 字（§4.7），所以「能关」是硬条件
图像（出图 / 锁脸）	`qwen-image-3.0`	支持参考图 `edit`；返回字节不返回 URL（媒体地址约 1 小时过期）；横评按跨页一致性拍板	只支持纯文本出图的模型，锁脸只能靠 prompt 祈祷，做不出一致性闭环
视觉（比对 / 审核 / 读照片）	`deepseek-flash`（缺省回落 `LLM_*`）	同端点、同 key、同管道；一个模型干三件事，只是三个接口	另起一家要多三处超时与三处错误翻译，而收益量不出来
语音（朗读 / 克隆）	`qwen-audio-3.0-tts-flash`	30 秒样本克隆、情绪标签能落到每一页 `mood`；生命周期有 `release`	克隆音色绑死在创建它的模型上（实测跨模型 400 `[411]`），所以「能解绑」是一等要求
检索	字符 bigram + BM25，索引是一个 JSON 文件	在几百条短句上排序可解释（能说「命中 12 个 bigram」）；索引与内容同仓、可判定	向量库：2026-10-19 实测网关里 26 个已服务模型**没有一个支持嵌入**；且索引与书必然不同步
AI SDK	不引（自写 `http` / `replay` / 工具循环）	流式、工具调用、四类能力的差异要看得见；回放包是离线验收的前提	Vercel AI SDK 会把供应商差异藏进适配层，出问题时无法定位到协议那一层（ADR-0004）
Schema	自写 `Codec<T>`（约 300 行）	一份定义同时出 JSON Schema 与运行时校验；错误带路径	zod 只解决校验，不解决「喂给模型的 Schema 与验收用的是不是同一份」
规划时工具调用	实现、量过、**默认关**	三臂对照：`tools` 每本恰好调用 4.0 次（4 就是上限，模型从不自己停手），中位 21 s vs 11 s	代价确定、收益不确定（一次过 4/5 vs 5/5），所以不默认开（ADR-0013）

4.1 集成方式

4.1.1 能力接口。 按能力命名，不按供应商命名（ADR-0002）；图像返回字节不返回 URL（供应商媒体地址约 1 小时过期）；生命周期方法是一等公民（`VoiceSynthesizer.release` 不是可选扩展，缺了隐私承诺在代码层就是假的）。`edit` 是可选**方法**而不是 `generate` 的可选字段——「这家不支持参考图」在类型上就看得见，没有「传了但被忽略」。

4.1.2 结构化输出。 自写 `Codec<T>`（约 300 行，ADR-0004 不引 zod）：`describe()` 出 JSON Schema 喂模型，`parse()` 做运行时校验。一份定义两个用途——分两份迟早会漂，漂了的症状是「告诉模型要 A、按 B 验收」，通过率莫名偏低。错误必须带路径（`nodes[3].mood`），否则重试提示等于让模型重新猜一遍。

4.1.3 流式。 `stream()` 是接口必填；两条硬约束有测试：同一响应下 `stream()` 与 `complete()` 结果逐字段相等（否则流式就是悄悄改输出的开关）；`onDelta` 每段必须是模型真写完的字符，**半个字段不算数**。流式与工具调用互斥：工具循环要完整回包，增量与 `tool_calls` 分片拼装是两件都不简单的事。

4.1.4 工具调用：实现了、量过了、默认关。 `tool-loop.ts` 四件工具（检索 / 书架 / 自检 / 角色段），工具抛错不终止循环，错误原文喂回去；步数用完必须说出来，不许静默截断。三臂对照里 `tools` **每本都恰好调用 4.0 次**（4/4/4/4/4），4 就是上限——模型从不自己停手；一次过 4/5，另外两臂 5/5；中位 21 s vs 11 s。**代价确定、收益不确定，所以不开**（ADR-0013）。`check_draft` 是这组里最值钱的：把「写完被整本拒发」变成「模型自己改回去」。

4.1.5 共读版两步规划。 一次写整张表时，请求 20 页的草稿在 **13–37 个节点**之间乱跳，五次重试只是重抽五次；`LLM_MAX_TOKENS` 从 16000 抬到 32000 也没改善——限制它的不是输出预算，是**自己数自己写了多少**。现在先写提纲（每页一句，三个数组），再分段展开（K 行 → K 页，`minItems` / `maxItems` 钉死）；树形模型一个字不写，由 `plan-shared.ts` 拼。于是「两条路各 20 页」是构造出来的。

4.2 Prompt 与工作流设计

分工： system 放身份、输出形状（JSON Schema）、图标词表、红线、输入约定——不随书变，可整段缓存；user 放主角、年龄档、爱好、家长原话、改稿意见、检索块——这一本的内容，放最后，让模型读到的最后一件约束是「别重样」。

版本号是可比性的界。 三份提示词各自带版本，进 `Provenance.promptVersion`：

提示词	版本	这一版治什么
故事表（独读）	`story-plan@v6`	页数从「约」改成硬约束，公式写进提示词；删掉「两支差不多」那句（它会教模型交废稿）
共读版	`story-shared@v2`	v1 两支几乎一样；v2 从分岔起各走各的，只最后 1–2 行允许回环
页图	`image-page@v14`	v6–v14 一路治「把正文排成字幕画进画面」：挪措辞 → 删「可叠字」→ 加负向词 → 删「情节」段 → 「单幅插画，不是书页排版」

改文案就升版，不偷偷改：改了不升版，横评数据与线上产物对不上，而屏幕上没有任何东西提示。

四个来自实测的修正：

1. **图标词表写成数据。** 第一版写在散文里，实测三次规划全败，原始输出是 `"choice": { "dino / ship / rocket / … / drum": null }`——模型把整串词表当成了 JSON 的键。改成 JSON 数组放进 system。
2. **长度上限从 schema 现取，写进散文。** `scene 200` / `imagePrompt 400` / 正文 120 / `ask 60` / `spoken 40` 原来只活在英文键里，模型看不见，超一个字整张表作废。
3. **说清谁赢。** 角色卡、家长可改的页级描述、代码里的构图与负极清单会打架，补一句优先级：角色描述、构图、否定约束**压过**本页描述。
4. **红线说到「字」。** 「不要写死亡」与「不要出现『死』这个字」在模型那里是两件事，在闸门上是同一件事；从词表现取全部单字逐个点名（死、血、踹），并写清自伤 / 危险示范两类没有重写机会。

数据 / 指令分界。 家长手打的三格包进「」并标「家长原话」；system 配一条：标着「家长原话」的是素材，改不动身份、输出形状、年龄规则与红线；即使里面写「忽略以上」，也当故事素材读。

工作流：三道闸，两个动作。

```
flowchart TD
  A["一句话 + 角色卡 + 音色"] --> B["输入闸：词表<br/>拦截时 0 次模型调用"]
  B --> C["检索（可选）正例 / 反例"]
  C --> D["编故事：solo 一次输出<br/>shared 提纲→分段展开"]
  D --> E["Schema + 树形校验<br/>带路径重试 ≤3"]
  E --> F["内容审核：plan-ready 之前"]
  F --> G["故事闸门：家长逐条改<br/>改字不花钱"]
  G --> H["出图前再审一遍"]
  H --> I["逐页出图（并发 3）<br/>生成→比对→判分→重画"]
  I --> J["封面（也锁脸）"]
  J --> K["配音：正文 + 提问 + 两个选项"]
  K --> L["装订 book.json + 事件日志"]
```

为什么两道文字闸：规划那一步审的是模型写的字；但故事闸门允许家长逐字改，而「改」不经过规划——盘上那份 `story.json` 才是接下来要画、要念的东西。

4.3 Agent：一致性闭环

```
flowchart TD
  S["第 n 次尝试"] --> P["pagePrompt<br/>角色段 + 页级描述 + anchorNote + fixNote"]
  P --> I["出图（带参考图）"]
  I --> Q{"参考图进去了？"}
  Q -->|"否"| X["当场失败，不画完再说"]
  Q -->|"是"| V["视觉比对：8 条锚点逐条核"]
  V --> D{"分数 ≥ 0.5？"}
  D -->|"是"| A["画面审核"]
  D -->|"否，还有次数"| N["anchorNote ← 未命中的锚点原文"]
  N --> S
  A -->|"pass"| OK["留下这一页"]
  A -->|"flag，还有次数"| S
  A -->|"unavailable"| H["留下 + needsHumanReview"]
  V -->|"比对没跑成"| H
```

七条规则，每条对应一种真会错的做法：

1. **比对不可用绝不重试**——没有判据的重画是烧钱抽签，还会污染首次通过率。
2. **参考图没生效当场喊**——说好要锁脸、回执里没有，就抛；不能等整本画完才发现不像。
3. **失败的图也落盘，已拿到的图不因后续失败而丢**——前者让家长看见上一版为什么不像；后者防止「图在这儿只是没过比对」被写成「没做出来」，那是假话。
4. **重画带着上一轮诊断，且只认最新一次**——把「哪几条锚点不像」翻回卡上原文注进下一次 prompt；「第 1 次不像、第 2 次像了、第 2 次被画面审核拦下」时，第 3 次不能拿到过时的结论。在此之前提示词循环外算一次、原样再用：机器只是拿同一张指令再抽一次签，闭环靠人合上。

5. **并发池的单位是整页的一生**——上限 3 只许并发页与页；不许「先全部出图、再统一比对」，那会让判断与执行分家，`anchorNote` 悄悄失效。

降级三档： 比对不可用 → 不重画、标「未核对」、`needsHumanReview`；一致性不过且次数用完 → 留最后一张，写清为什么停在第几次；画面审核 `flag` 用完次数 → 留图，封面这一档整本失败（刻意取舍：有清单的书不能再改封面）。

4.4 RAG：索引是一个文件

```
flowchart LR
  Q["查询串<br/>主题 / wish / 改稿要求"] --> F["硬过滤<br/>owner / 年龄 / 主题 / 形态"]
  F --> C["候选集"]
  C --> S["BM25：字符 bigram<br/>k1=1.2 b=0.75"]
  S --> T["两档阈值<br/>整库 2 / 已收窄 1"]
  T --> P["正例 top-k：照着节奏写"]
  T --> N["反例 top-k：他读过的，避开"]
  P --> M["提示词末尾 / 检索工具"]
  N --> M
  M --> V["provenance：语料版本 / 分数 / why"]
```

四个决定：

1. **字符 bigram + BM25，不引分词器。** 中文没空格，按词切要多一个原生依赖、一份词典、一种「这次怎么切得不一样」的新失败模式。bigram 在几百条短句上排序可解释：共享的字越多、越少见，分越高；`why` 能说「命中 12 个 bigram」——换成分词 + 向量就得说「余弦 0.71」，而 0.71 解释不了任何事。
2. **硬过滤在前，打分在后。** 年龄 / 主题 / 形态是过滤键，不是特征——做成特征的症状是「8 岁档的句子漏给 4 岁档，分数还挺高」。`example` 取同档或相邻一档；`avoid`（他读过的）只守 owner 与形态，「读过就是读过」。
3. **空结果是合法结果。** 返回 `[]`，上游照常编。不许兜底成「随便给几条」：不相关范例比不给更坏，它会把模型引到错误方向，而界面上看不出来。
4. **`owner` 是隐私边界。** `avoid` 只取这个人的；`example` 只取库 + 自己的。否则别人家孩子的书正文会被喂进这个模型的上下文。

索引是文件（ADR-0011）：`index.seed.json` 随仓库提交，进程内读一次；自家写的书每次现场拼（几十本 × 20 页是毫秒级，而落盘索引与书必然不同步）。到几百本书要换实现。

增益怎么报：

轮次	设计	结果
一	开 / 关各 10 本 × 两轮	预声明判据第一轮未达、第二轮正好达到，差的那一本换边
二	30 本/臂；阈值两档；剂量从 6/10 主题到 10/10	两端都没过：重复度 +0.5 pp（p=0.81）、超长句 −0.3 pp（p=1.00）
三	50 本/臂；独立字频表 + 内容红线命中	OOV 八个档位无稳定优势；红线命中 0/50 对 0/50（p=1.00，MDE 13.3 pp）

第二轮附 MDE：重复度 4.9 pp、超长句 16.1 pp，观测差约 1 pp，比模型自己的抖动小一个数量级。不是「差一点」，是**远在可检测范围之下。**★ 自曝一处口径错：第一轮门槛写「≥5 pp」，而对照组基线只有 3.3 pp（重复度不可能低于 0）——**那道门槛数学上就达不到。**★ 一条硬的正面读数：两轮三臂，与范例的句子重合率**全 0.0%**，没有照抄污染。

第三轮的两条读数要分开写。① **超纲字**换成独立标尺（Jun Da《现代汉语字频表》前 300–3500 字，`scripts/rag-safety-endpoint.mts` 同批数据离线复算）：开检索的三条臂在八个档位里没有一个稳定更低（top 1000：19.07% → 19.34%，top 2000：3.34% → 3.85%），此前那个「13.4% 对 13.7%」的代理量结论因此被独立数据确认，不是标尺不好。② **内容红线命中**在 50 本/臂 上是 **0/50 对 0/50**（Fisher p=1.00，MDE 13.3 pp）——这个端点已经饱和；第二轮探索性读数里那 4/30 跑在 `story-plan@v4`，今天是 `@v6`，跨版本不可比，不能当基线。**结论：四类端点（Schema 通过率 / 重复度与超长句 / 超纲字 / 红线命中）、三轮预注册，没有一个测出可复现的增益。** 这一栏报的是「检索架构合理、可解释、可复现；在当前语料与模型上没有可测的生成质量提升」，**不宣称提升。**

4.5 多模态集成

模态	模型	输入	输出	失败语义
文本	`deepseek-flash`	system + user / messages	JSON 故事表 / 一段话	重试 ≤3，带路径反馈
图像	`qwen-image-3.0`	prompt + size + 参考图	字节 + 用量读数	页级失败不终止全书
视觉	`deepseek-flash`	两张图 / 单张图	分数 + 锚点 / 条款 id	`null` = 未核对，不算通过
语音	`qwen-audio-3.0-tts-flash`	文本 + 音色 + mood	音频字节	页级失败；书照常装订

两条跨模态约定：图像返回字节不返回 URL；视觉一个模型干三件事，用三个接口而不是三个工厂（同端点、同 key、同管道，分开只会多三处忘了配超时）。★ **端侧推理没做，不宣称**：端上发生的是预生成资产的离线阅读，不是端侧模型推理。

4.6 MCP 集成

```
sequenceDiagram
  participant C as Claude Desktop / Code
  participant M as MCP server（stdio）
  participant E as 引擎
  C->>M: initialize（JSON-RPC 2.0）
  M-->>C: tools/list（7 条）
  C->>M: tools/call plan_book
  M->>E: planBook（真引擎）
  E-->>M: 事件 + StoryPlan
  M-->>C: 正文 + 进度通知
  C->>M: tools/call illustrate_book
  M-->>C: 立刻返回「开工了」
  C->>M: tools/call book_status
  M-->>C: 人话进度（describeEvent）
```

手写 JSON-RPC（ADR-0012），不引 SDK：这一层是薄壳，逻辑在 `lib/mcp/`，七条工具包的是引擎四个动作，过程走的是**早就在那儿的事件协议**——`events.ts` 写着「同一串事件喂三个消费者：前端、MCP、日志」，MCP 就是第三个。

工具	干什么	花钱
`list_children`	这个账号下的孩子	不花
`character_card`	锚点 + 画师会拿到的那段	不花
`list_books`	书架	不花
`read_book`	一本书的正文全文	不花
`book_status`	做到哪一步	不花
`plan_book`	编一版故事，不画图	1 次文本 / 共读版 4–5 次
`illustrate_book`	按盘上那版故事出图（异步）	每页一次出图

长任务异步：一本 20 页要几十分钟，任何客户端工具超时都撑不过去；让一个必然超时的工具存在，就是把这一栏做成演示事故。代价（客户端断开 → 进程退出 → 这一轮跟着死）写进台账，不假装解决。

怎么保证没骗人（`mcp-session.mts`，14 条判据）：① MCP 与 CLI 的 `book.json` 去掉时间字段后**逐字节相同**，事件流语义相同（30 条）；② 给 `progressToken` 收得到、**不给就一条都没有**；③ 插画事件里 7 个 `assetPath` 逐个 stat。三条缺一条，都可以靠「两串都指向空气的事件流」蒙混过去。

4.7 优化策略

方向	做法与读数
上下文	system 可整段缓存；检索块放最后，空结果整段不出现；页图从 v7 起不再喂正文；默认关思考（4096 预算下实测正文 0 字、思考 9072 字）
成本	先审后画；锚点回灌（¥1.8–5.3，未兑现）；换便宜视觉模型（¥2.2–3.5，改 env）；页数 20→12（¥3.1–4.4）；额度按本数
速度	阅读零调用；并发池 3（串行 77.7 s / 455.6 s 压到 1/3 量级）；两步规划 20 页 4–5 次调用、21–26 s
稳定性	Schema + 树形双校验、带路径重试；提示词版本化；enum 大小写宽容但换判据必须报错；视觉一律关思考
缓存	已生成资产就是缓存；回放包；价目表从 `/v1/models` 免费 GET；检索索引进程内读一次，自家书现场拼

★ 出图本身十几秒一张：干净探针（3 路并发）量到 1024^2 **15.2–17.7 s**、页图 1536×1024 **16.7–18.4 s**。文档里那个「154 s/页」来自一次**网络中断**的跑测，含重试与等待，不能当典型值；真书 12.5–174.2 分钟的差异来自重画、比对、排队与超时。

4.8 AI 安全与可控性

一道词表闸，三处落点。

落点	审什么	处置
① 家长自由输入	主题、愿望、改稿要求	`planStory` 最前面；`flag` / `block` 一律拒发，**0 次调用**
② 模型写的字	正文 / `scene` / `imagePrompt` / 选择点 / 书名	`plan-ready` 前 + 第一次出图前；可改条款带反馈重写
③ 画出来的图	图上没有字可扫，只能问视觉模型	出图后；`flag` 重画，`unavailable` 不重画

`pass` / `flag` / `block` / `unavailable` 是四件不同的事。★ `flag` 不是「提示一下照样放行」——一个会放行的警告不叫闸门。

读数【A】：10 条判例 **9 条拦下**，剩下 1 条**故意用委婉说法绕过、按预期漏过**（把边界钉在纸上）；96 段真样书正文 **0 误拦。**词表抓不到谐音、拼音、委婉说法、外文与「没有脏字的吓人」——所以**不许**说「覆盖了红线」，能说的是「命中的一律拦下，词可枚举可复核，剩下那几类今天没有判据」。

第二层：只在「可疑」时多问一次模型。 词表之外还有一层兜底，但它刻意不是「每本都问」：

- `suspicion.ts` 只看信号、不判违规：家长原话里的离别词根、正文里的信号词与委婉二元组、超长句、短得反常、句子数少于页数；
- 命中才问 `review-judge.ts` 一次；**它报的每一条都要回原文逐字找到才算数**，找不到的不算；
- 报了就让这一版带反馈重写；没跑成则放行，并在事件里如实写 `unavailable`（不拿网络错误当违规）；
- 读数【A】：盘上 17 本干净书（5 真书 + 12 样书）每本 3 次，**触发信号 0/17**；模型报了 1/17（3/51 次，样书《慢慢来》第 8 页 R-07「说教」）；**报了但原文找不到的 0 条。**漏拦率**没有量**——这批书没有人工标注的真值，所以它仍然是兜底，不进「覆盖了红线」那句话。

画面审核是兜底，不是判据。 第一版条款在 87 张真图上误报 **32/87 = 36.8%**；改条款后同一样本重跑 **0/87**——但**不是独立验证**（这 87 张就是据此改条款的那批）。最难的反例 32 张 × 3 次翻出 2 次误报（2/95 次调用），两次都是「3 次里报 1 次」的边界画面。所以处置是「图留着 + `needsHumanReview`」，不是删图；封面才重画，因为它没有第二次机会。

隐私与数据最小化： 照片原图与录音样本不落盘（`check:family` 真跑两条路再满盘搜，带对照针）；逐字增量不进日志；资产按人分片，删除按位置报数，音色删除会向厂商 `release`；密钥只有 `.env.local` 与 `models.runtime.json` 两个落点，都在 `.gitignore` 里；管理页响应里**一个 key 都没有。**`/privacy` 把「存了什么、发给谁、留多久、怎么删」写成一屏给家庭看，不需要登录；两件不体面的事也照实写——**没有自动过期**，以及这是自托管的一份，能读到那台机器磁盘的人就能读到那些文件。

4.9 证据清单

结论	等级	读数或说明
一致性阈值 0.5	A	0.93 / 0.20 / 0.05 / 0.55；小样本，要重标定
五本真书首次通过率	A	2/11、4/12、5/10、3/6、4/5
重画率	A	1.33–2.00 次/页，随模型与阈值晃
RAG 增益	A（不显著）	三轮未过；MDE：重复度 4.9 pp、超长句 16.1 pp、红线命中 13.3 pp；OOV 八档无优势
锚点回灌增益	A（判不出）	p8 +3 pp、p10 +17 pp，区间交叠；12 张/组 MDE 41–51 pp
图像单价	未量到	厂商不回传费用；定价页 JS 渲染抓不到，不记账
参考图对一致性的提升	未量	只证明「参考图进了请求」，没做开 / 关对照
语义复核的触发与误报	A	17 本干净书 ×3 次：触发 0/17；报了 1/17；原文找不到 0 条；漏拦率未量

结论	等级	读数或说明
20 页成本 ¥5.8–11.6	A	图像按 0.20 元/张
3–8 岁家庭规模	假设	七普 0–14 岁 253,383,938，3–8 岁未单列，均匀分布粗推 ≈1 亿

五、核心功能实现

5.1 角色卡：把「长什么样」变成资产

要求	实现	没有它会怎样
可引用	`promptFragmentOf(card)` 派生唯一角色段	20 页 20 段描述，改一次要重画 20 次
可核对	`checklistOf(card)` 把锚点变成核对清单	一致性退化成「像不像」三个字，阈值无从校准
可失效	`cardDigest(card)` 是语义指纹	旧图与新卡混在一本书里，页面上看不出来
可追溯	`Provenance.cardRevision` 记每页出自第几版	模型换代后无法说明哪张图是哪版画的

8 条锚点分硬软：硬（骨相、眼睛、头发、头身比、肤色）逐条核；软（特征记号、常服、补充）允许合理变化，出现矛盾才算失败。分档是产品判断：把「常服」当硬锚点，孩子换衣服那页会被判不合格，而它恰恰是家长最想要的变化。一条不变式比所有函数都重要：**卡里每一项都必须跨页不变**，姿势、表情、场景、光线、天气永远不进卡。

照片那一路（`analyzePortrait`）的产物是**建议，不是事实**：模型读出锚点与标签，界面要家长逐条核对，不直接写卡。

5.2 两个动作与故事闸门

```
// src/lib/engine/index.ts（签名即边界）
buildCharacterCard(...)              // ① 资产化：做一次，跨页跨书复用
planBook(request, deps)              // ② 编故事，停在闸门之前
illustrateBook(request, tree, deps) // ③–⑦ 逐页画 / 封面 / 配音 / 装订
runBook(request, deps)               // 上面两步的复合
```

拆开是「故事闸门」：出图是这条流水线唯一真花钱的一步，原先紧跟编故事——家长读到第一个字之前，整本的钱已经花了。拆开后，界面把故事摊出来让家长逐条改，点「就按这个画」才出图。`runBook` 留着不是为了兼容：脚本、横评、离线跑测走它；它必须是两个动作的复合，否则「引擎不碰 React」跑通的那条路与产品走的那条路就分了家。`split.test.ts` 钉着「两条路产出同一串事件、同一本书」。

5.3 一致性闭环的代码思路

```
for (let attempt = first; attempt <= last; attempt += 1) {
  const prompt = pagePrompt({ card, page: node.imagePrompt, mood,
    ...(anchorNote ? { anchorNote } : {}) })
  const response = edit
    ? await edit.call(image, { prompt, size, referenceDataUrl, negativePrompt })
    : await image.generate({ prompt, size, negativePrompt })
```

```
  if (edit && requireReference && response.referenceApplied !== true)
    throw new EngineError('reference-invalid', '要求锁脸，但参考图没进请求')

  asset = await store.put({ path: `page-${n}-a${attempt}.png`, bytes: response.bytes })
  const compared = await vision.compare({ referenceDataUrl, pageDataUrl, checklist:
checklistOf(card) })
  consistency = verdictOf(compared, threshold)     // pass / fail / unavailable

  anchorNote = consistency.verdict === 'fail'
    ? anchorNoteOf(card, consistency.missedAnchors) // 诊断回到执行器
    : undefined

  if (consistency.verdict === 'fail' && attempt < last) continue
  break
}
```

四点讲究：`pagePrompt` 每轮现算，第 1 次与改动前逐字节相同（所以首次通过率不受影响）；**记账在判断之前**，钱在 `generate` 返回时就花了；文件名带 `attempt`，失败的图也留；`needsHumanReview` 收四种情况（没通过 / 没核对成 / 画面没通过 / 画面没审成），**缺席不许被读成通过。**

5.4 一棵树，两种形态

`buildTree(form, title, nodes, pages)` 是纯函数：恰好一个选择点；两支各自收尾、不汇合；两条路各自恰好等于请求页数。

页数有一个容易读错的单位：**两形态下都是「一条路走下来几页」，不是「表里几个节点」。**共读版表里一定更多——8 页路长、1 层分支，表里约 11 个节点。界面在花钱那一刻写「读下来 N 页，一共要画 M 页的图（含走不到的那一支）」。「走不到的那一支也要画」不是浪费，是「孩子真的能选」的价钱；不做多层，是因为选择的上界由年龄给（1 层 27% 的书有一支读不到，2 层 43%，3 层 64%）。

5.5 两台阅读器

项	独读版	共读版
结构	线性，一屏一图一句	树，恰好一个选择点；选完按那条路走
选择点	没有	两个大按钮，**图标 + 朗读**双通道；图标来自 20 个词的固定表
朗读	每页正文	正文 + 提问 + 两个选项，≤4 段/页
生成	预生成	预生成；**选完零生成**
手机	竖屏提示横过来；横屏铺到 98.5%	同左

朗读去重键是 `(voiceId, mood, textHash)`，不是页码：共读版主干页被多个分支共用，合成两次是白花钱；同一段文字换个语气是另一份录音，所以 `mood` 必须在键里。复用的页 `asset` 指向同一个文件（`reused: true`），这不是漏了。

5.6 过程可视化与断线重放

一本书跑几分钟到几十分钟，「正在画第 7 页」「第 9 页不太像，正在重画」本身就是产品要展示的东西。纪律：

- **阶段轨只有 4 格**（编故事 / 画 / 配音 / 装订），检索与工具调用落在「编故事」的 `note` 上——摆一个只亮一次的节点就是骗人。
- **进度不报假数**：写作进度曾写「已写 10 / 8 页」，分母是请求页数、分子是模型写了几个 JSON 对象；现在整行去掉数字，只写「正在思考中」。
- **失败不静默**：规划失败、路由 4xx/5xx、流被打断原来合成一句「编故事这一步没有回书号」，现在分别说；上界那一轮不再发「正在重写（第 3 / 3 次）」——那是空头承诺。
- **重放**：`GET /events` 按 `seq` 重放，帧格式与实时流逐字一样；刷新、断线、换设备都走同一条。

5.7 首页、动效与管理页

首页是 12 张封面绕成的 3D 环，第二屏演示书翻页，第三屏亮点。三个互相咬合的数写在代码与文档里：`HANDOFF_START`、`hero-orbit.css` §5 的 `--out-start`、`smoothstep(.06, .84, p)`——改一个要同时改另两个；`StartCreating` 的 `EXIT_MS`（200 ms）与 CSS 退场 `transition` 是同一个数。滚动驱动是自写的 `useScrollDriver` / `useScrollTick`；亮点那张「被一角托起的纸」用 GSAP `quickTo` 跟指针；零 Web 字体；`prefers-reduced-motion` 下每处动效都有**静止终态**；配色两条闸（写死颜色、4.5:1 对比度）。

管理页四张卡，每张改三格：模型名、接口地址、api-key。三处不显然：改完立刻生效（`serverEnv()` 每次请求现读，无模块级缓存）；响应里一个 key 都没有，只回「配了没有、从哪儿来」；**空不等于清掉**——只换模型名的人不该顺手清了 key。

四张卡下面还有一块「额度」：发兑换码（明文只在这一屏出现一次，旁边一个 CSV 下载）、给某个账号直接加额度。顶上那个「对账差」平时不显示——它是 `book_credits` 求和与 `credit_accounts.balance` 的差，只有两边对不上才冒出来。

5.8 手机那一档

手机不是把桌面缩进去。五个视口 × 每条页面路由都不横向溢出；看绘本时竖屏提示横过来，横屏铺到视口高的 **98.5%**，翻页钮拆进左右页边落在拇指下面；首页只有两节，环整块不演，**12 张封面一张不取。**最后这条两头都量：手机上「一张都没取」，桌面上「三节都在、12 张取全」——只量一头的话，一个「手机上干脆不渲染首页」的实现也会全绿。

5.9 交付出去：分享、打印、站内信

书做完之后还有一段路：**送到别人眼前。**

- **只读分享链接（`/r/<票>`）。** 对方不用登录、不用装东西，打开就是阅读器；缺省 30 天到期（1–90 天可选），随时可以收回，收回后页面与图同时 404。盘上只存票的哈希，原文只在生成那一次出现；「再给我看一眼上次那条」做不到，所以语义是「发一条新的 = 旧的作废」。判据在 `chk-share-link.mts`：匿名可读、过期 / 收回 / 改一字节都 404、无写按钮、**零模型调用。**
- **A4 打印 / 存 PDF（`/print/<书号>`）。** 摊成几张 A4 横向的纸，交给浏览器自己的打印；实测一本 6 页的 PDF，判据在 `chk-print-pdf.mjs`：纸是 A4 横向、页数对得上、字体嵌入、文件 < 20 MB。
- **站内信（`/notices`）。** 一本画完会收到一封；一屏最多 60 条，保留 90 天，更老的不删（去书架看）。

5.10 额度、兑换与对账

额度是钱那一侧的事，整条落在 Java。**账本 `book_credits` 只追加**，是「这个人的额度怎么变成现在这个数」的唯一答案；余额表 `credit_accounts` 是能原子扣减的缓存，两者恒等——管理页上那个「对账差」就是它们的差，只有对不上才冒出来。

事	做法
扣减	一本书扣 1 本；不够回 **402 + `no-credits`** 和一句人话，不是 403
开户赠送	新账号 2 本，`refNo=welcome` 幂等：重复登录、重启都不会再发
兑换码	库里只存 HMAC 与后四位；明文只在站长生成那一次出现（旁边一个 CSV）
补发	管理页给某个账号直接加额度；没有支付通道，也没有订单台账

为什么开户要送 2 本：对一本不满意、改完故事再来一遍是**新一轮生成、再扣一本**，只送 1 本的话第一次不满意就没有第二次了。上限就是这 2 本，被反复注册薅走的上限是每人两本——比「新来的人一本都画不了」便宜。在此之前，兑换码只有站长发得出来，而一个陌生人没有站长的微信。

六、测试与部署

6.1 测试策略

四层：**纯函数**进 Vitest（树、帧、校验、排序、检索打分、协议、去重），不拿 jsdom 猜 DOM 与 GSAP；**浏览器事实**用 headless Chrome + CDP 量（动效有没有真写 transform、翻页跟不跟手、有没有遮挡）；**端到端**打真路由、用真资产，必要时真花钱，不 mock 掉要证明的那一步；**闸门**是 `pnpm verify` 那七条（format / lint / typecheck / colors / scrim / family / test），外加一条独立的 `check:secrets`，提交前必须全过。

两条测试观：**判据要选「只有真做才会不同」的量**——「点了没报错」证明不了 hydrate，「元素在 DOM 里」证明不了可点；取「网络里有没有那个请求」「盘上文件在不在」「`assetPath` 能不能 stat」。**空态也会全绿**——未登录的书架什么都没量，所以探针自己签票、造真数据，「量到 0 个」判不过。

6.2 关键测试与探针

命令	判据	读数【A】
`pnpm test`	纯逻辑与集成测试	**1710 / 130 全绿**，4.9 s
`engine-run.mts --mode=stub`	不联网跑完一本；事件与资产齐全	6/6 页、7 次调用、**0.06 s**
`mcp-session.mts`	握手、7 工具、进度判别、与 CLI 等价、资产真在盘上	**14/14**，68 条消息
`chk-share-link.mts`	匿名可读；过期 / 收回 / 改一字节都 404；零模型调用	全过
`chk-print-pdf.mjs`	A4 横向、页数对得上、字体嵌入、文件 < 20 MB	全过
`chk-perf.mjs <URL>`	3 视口 × 3 路由，CPU ×4、连跑 3 次取中位	九格全「好」

命令	判据	读数【A】
`chk-mobile.mjs <URL>`	5 视口不溢出；横屏铺书；首页两副形态；封面两头量	全过
`chk-shared-reader.mjs`	阅读顺序、选完零生成、缺图兜底、键盘、断网	全过
`e2e-shared-reading.mts`	一句话到读完（真花钱；`--until=story` 到闸门）	可跑
`check:colors` / `check:scrim` / `check:family` / `check:secrets`	写死颜色；4.5:1 对比度；照片录音不落盘（带对照针）；密钥不入库	全过
`cost-model.mts`	价目表 + 真书出图次数与计费字符	报告落 `.out/cost-model/`

6.3 页面级性能

对**生产构建**量（三视口 × 三路由，CPU ×4、连跑 3 次取中位、每格冷缓存）【A】：

指标	首页 1440×900	`/booklist`	`/login`
LCP	**488 ms**	612 ms	524 ms
CLS	**0.000**	0.000	0.000
TBT	**92 ms**	—	—
First Load JS（首页）	**168 kB**	—	—

九格全落「好」。★ localhost 的秒数不是用户侧秒数：没网络延迟、没真实设备，量的是我们自己这段代码；同一构建隔 40 分钟复跑还能低三成，所以读作**上界**。稳的是：都远低于 2.5 s，CLS 九格全 0。

6.4 部署与配置

项	做法
拓扑	Nginx :443（:80 → 301）→ Next 3000 / Java 8080 → MySQL 3306，同机四件
证书	Let's Encrypt；certbot 的 systemd timer 每天看一眼，到期前 30 天续；续期走 `--webroot`
发布	构建到 `.next-new`，健康检查过了再换目录，失败自动回滚
目录	代码 `/opt/xiaozhujue/`；作品 `/var/lib/xiaozhujue/assets`，两棵分开
认证	JJWT HS256 + httpOnly cookie；浏览器只跟 Next 说话，Next 带 `X-Internal-Token` 打 Java
密钥	`.env.local` 或 `models.runtime.json`；生产建议 `MODEL_CONFIG_FILE=/etc/xiaozhujue/models.json`
回放	`mode=offline` 必须显式声明，不允许 live 失败悄悄退回
合规	页脚与登录页挂备案号并链到工信部备案系统

主要环境变量（详见 `.env.example`）：文本 `LLM_*`（默认关思考，开思考要配 16000 预算）；图像 `IMAGE_*`（地址必须到 `/api/v1`，改写默认关）；视觉 `VISION_*`（缺省回落 `LLM_*`，三个预算分别管读数 / 比对 / 审核）；语音 `TTS_*`（地址不回落，克隆音色绑模型）；部署 `MODEL_CONFIG_FILE` / `ASSET_ROOT` / `APP_JWT_SECRET`。

6.5 在线演示

地址 https://lbx99.xyz，账号 `123456` / `123456`。推荐 3 分钟路径：首页 → `/booklist` 读一本样书（零调用、零等待）→ `/home` 说一句话 → 故事闸门逐条改 → 「就按这个画」→ 画桌看阶段与重画原因 → 阅读器两种形态 → 书架上生成一条分享链接，或用 `/print/<书号>` 存成 PDF。★ 只有出图那几步真花钱；出图异步，一本 20 页要几分钟到几十分钟，关掉页面不会停，回来能重放过程。自己注册的账号开户赠 2 本，不兑换也能走完一遍。

七、总结与展望

7.1 成果

1. **一个跑得完整条链路的引擎**：四个动作、一份事件协议、四类能力适配器；stub 档 **0.06 秒**跑完一本，不联网、不花钱。
2. **一条可判分的一致性闭环**：出图 → 比对 → 判分 → 诊断回灌 → 重画；阈值按分布重标 0.5；未核对不算通过；失败图留档。
3. **两种形态、一棵树**：独读 20 页线性；共读恰好一个选择点、两支各自收尾；页数由算术钉死。
4. **一套可复现的质量体系**：1710 条测试、87 个探针、七道离线闸门；性能九格全「好」；MCP 14/14。
5. **一条能解释的成本曲线**：20 页 ¥5.8–11.6（换家前）；文本不到一张图的十分之一；重画是最大变量，也是最大优化空间。
6. **一条能交付出去的路**：开户赠 2 本、兑换码、只追加账本与对账差；只读分享链接、A4 打印 / 存 PDF、站内信、隐私说明页。

7.2 社会价值

留守儿童场景：在外打工的父母录 30 秒声音，孩子在家听爸妈读一本自己当主角的绘本。声音能跨距离。**这个场景我们验证不了效果**——没有访谈、没有试点、没有分发，这句必须写在前面。

能说的是产品能力对得上：生成不需要一行新代码（同一套「录 30 秒 → 克隆 → 预生成 → 落盘」）；读的那一刻不调模型，网络差也能翻；孩子那边不需要有人会操作（自动朗读 + 自动翻页）。两条「送过去」的路：一条只读分享链接（对方不用登录，30 天可收回）与一屏 A4 打印 / 存 PDF；家庭可以自己把它打印出来寄回家。公益那一档的正确形状是**由基金会 / 公益项目按本采购**，家庭侧零成本；用预置音色而不是克隆家长声音，可以省掉一次授权与一条隐私承诺。这些是路径，不是已验证的渠道。`/privacy` 把数据去向与删除入口写给家庭看，不需要登录——这是「告知」那一半；可勾选、可留存的监护人同意书仍然没有。

7.3 商业潜力

项	读数
单本成本	**¥5.8–11.6**（20 页；两个旋钮：视觉模型档、重画率）
成本结构	出图约七成；视觉核对三成；文本 + 语音不到 2%
定价	单本 ¥39；月订 ¥39/月含 2 本；年订 ¥399/年含 24 本【决策】

项	读数
毛利	单本 74–82%；月订 49–64%；年订 40–58%（C = 7–10 元）
对照锚点	纸质个性化 $29.99–39.99/本（≈¥210–280）【B】

一条由成本结构直接决定的规则：**额度必须按「本数」，不能按「时间」。** 边际成本随本数线性增长，「不限量」档位毛利必然崩；「每月 2 本」不是保守的营销设置，是成本算出来的边界。

★ 必须直说：今天**零用户、零渠道、零支付、零经营主体**；额度与兑换码已经上线（开户赠 2 本），但支付通道与订单台账没有做；机构版 ¥2000–3000/班/年是假设，没与任何机构谈过；TAM 只能读作「分母是谁」，不能读作金额。单位经济学乘以零个用户仍然是零。

7.4 后续规划

优先级	事	判据 / 备注
1	额度：每账号每月本数 + 全站硬顶	按本额度已上线：只追加账本 + 原子扣减 + 兑换码 + 开户赠 2 本；缺的是自动刹车与全站上限
2	送出去：离线包与推送到设备	只读分享与 A4 打印 / 存 PDF 已上线；还缺能双击打开的文件与设备通知
3	支付与订阅状态机	下单 / 回调 / 对账 / 退款台账
4	可勾选、可留存的监护人同意书	`/privacy` 只做了「告知」；「同意—留存—撤回」那一节还没有
5	语义审核档	已接成兜底（`suspicion.ts` + `review-judge.ts`，逐字回原文核对）；仍不进「覆盖了红线」的验收
6	一致性阈值持续标定	样本变大重跑；判据是「双峰还在不在」
7	RAG 换语料或改机制	补 6-8 / 8+ 档真实样例，或把字表当硬约束；再换判据没有意义
8	共读版小页数下限	今天 4 页 1/5、6 页 1/2；抬到稳的档，或继续推提示词

八、创新点清单

按官方要求分开列：**技术创新点**回答「这件事在工程上怎么做成」，**应用创新点**回答「它改变了谁的哪个动作」。

8.1 技术创新点

#	创新点	为什么不是常规做法	证据
T1	一致性闭环把「判分」接回「执行」	多数做法是「画完再看一眼」，诊断止于日志；这里把未命中的锚点原文注回下一次 prompt，才叫闭环	§4.3；`illustrate.ts`；`anchorNote`
T2	并发池的单位是「一整页的一生」	「先全部出图、再统一比对」更快，但会把判断与执行拆开，T1 悄悄失效	§4.3 规则 5；`DEFAULT_PAGE_CONCURRENCY = 3`

#	创新点	为什么不是常规做法	证据
T3	一个 `form` 两形态，页数由算术钉死	不做两套结构、两个入口函数；共读版两条路各自恰好等于请求页数，是构造出来的，不是祈祷出来的	§5.4；`tree.ts` / `plan-shared.ts`
T4	故事闸门：成本结构决定交互结构	把唯一花钱的一步从「编完就画」拆到「家长点头才画」；`runBook` 仍是两动作的复合	§5.2；`split.test.ts`
T5	同一串事件喂三个消费者	前端可视化、MCP 返回、过程日志共用 `describeEvent`，人话只写一遍	§3.4、§4.6；`events.ts`
T6	索引是一个文件，`owner` 是隐私边界	不引向量库；正反两极一次取且不重叠；「别人家孩子的正文」被 `owner` 挡住	§4.4；ADR-0011；`corpus.test.ts`
T7	负结果也当结论写	RAG 三轮预注册、四类端点没有一个测出可复现增益，就报「不宣称提升」；MDE 与门槛错配也写出来	§4.4；`rag-bakeoff`
T8	语义兜底要求「逐字回原文核对」	模型说违规不算数，报的每一条都要在原文里找到；找不到就不算；没跑成写 `unavailable`	§4.8；`review-judge.ts`
T9	自写 `Codec<T>`：一份定义同时出 Schema 与校验	不引 zod；「告诉模型要 A、按 B 验收」这种漂移从结构上消失	§4.1；`src/lib/schemas/`
T10	额度账本只追加，缓存与账本恒等	余额可原子扣减，真相在账本；「对账差」只有在对不上时才冒出来	§5.10；`book_credits` / `credit_accounts`

8.2 应用创新点

#	创新点	改变了谁的哪个动作	证据
A1	睡前那档**不给孩子选择**	把「互动越多越好」的默认值翻过来：越选越兴奋，睡不着；形态规则反过来写进提示词	§1.2、§5.5；`story-plan` 提示词
A2	白天那档**恰好一个选择点**，图标 + 朗读双通道	孩子不识字也能自己选；两层以上分支不做，因为选择的上界由年龄给	§1.2、§5.4
A3	先看字、再花钱	家长在付费之前能逐条改故事，不必「不满意就重来一遍」	§2.2、§5.2
A4	父母的声音跨距离	30 秒克隆 + 预生成 + 自动朗读 / 翻页；祖辈不需要会操作	§1.3、§7.2
A5	一本书能送出去	只读分享链接（不用登录、30 天可收回）+ A4 打印 / 存 PDF + 站内信	§5.9；`chk-share-link` / `chk-print-pdf`
A6	把数据去向写给家庭看	`/privacy` 不需要登录，五节白话 + 折叠的出处；没有自动过期与自托管这两件不体面的事照实写	§4.8；`PrivacySheet.tsx`
A7	手机是另一副形态	横屏书铺到视口高 98.5%，翻页钮拆进两条页边；首页两节、12 张封面一张不取	§5.8；`chk-mobile`
A8	一个陌生人能自己走完	开户赠 2 本、兑换码、按本额度；不靠站长微信也能画完第一本	§5.10；`WELCOME_BOOKS`

附录：写作依据对照表

本文结论	依据（文件 / 命令）
1710 条测试 / 130 个文件	`pnpm test`（4.9 s）
后端 98 条 JUnit	`mvn -o -f server/pom.xml test`（0 失败 0 错误）
引擎 0.06 秒跑完一本	`node scripts/engine-run.mts --mode=stub`
MCP 14/14	`node scripts/mcp-session.mts`
20 页成本 ¥5.8–11.6	`node scripts/cost-model.mts`；`docs/business.md` §1.5
九格 Web Vitals	`node scripts/chk-perf.mjs <生产构建 URL>`
手机 98.5% / 首页两副形态	`node scripts/chk-mobile.mjs <URL>`
分享链接四条判据	`node scripts/chk-share-link.mts --base=<URL>`
打印 / PDF 四条判据	`node scripts/chk-print-pdf.mjs --base=<URL>`
照片与录音不落盘	`pnpm check:family`
语义复核 17 本 0 触发	`node scripts/safety-judge-real-books.mts`
阈值 0.5 与五本真书读数	`.out` 下的 live 记录；`docs/tech-selection.md` §9.1.3
规模数字（444 文件 / 91,334 行 / 77 Java 文件 / 80 提交）	`find src -name '*.ts*' | wc -l`、`git rev-list --count HEAD`